

Министерство науки и высшего образования РФ
Национальный исследовательский университет ИТМО

Математическая статистика

Расчётно-графическая работа №1

Описание выборки. Оценивание параметров. Доверительные интервалы

Вариант: А-3

Объём выборки: $n = 200$

Санкт-Петербург, 2025–2026

1. выборки (задание 4.1)

1.1. Числовые характеристики

В таблице 1 приведены основные выборочные характеристики для столбцов X1, X2, X3.

Таблица 1. Числовые характеристики

Характеристика	X1	X2	X3
Закон	Exp(λ , c)	N(a, σ)	U(a, b)
n	200	200	200
min	10.73	25.17	26.52
max	469.49	90.60	68.35
Среднее $\bar{x}$	64.05	57.66	47.84
Медиана m_e	48.57	58.82	48.94
Дисп. смещ. S^2	2884.29	157.31	142.73
Дисп. несмещ. σ^2	2898.79	158.10	143.45
Ст. откл. S	53.71	12.54	11.95
Ст. откл. σ	53.84	12.57	11.98
Q_{25}	29.28	48.81	37.92
Q_{75}	87.56	65.62	58.12
IQR	58.28	16.80	20.20
Асимметрия	2.918	-0.170	-0.107
Эксцесс	15.728	-0.289	-1.156

2.2. Гистограммы и эмпирические функции распределения

Для выбора числа интервалов использовалось правило Скотта: $h = 3.5 \cdot \sigma \cdot n^{(-1/3)}$. Для X1 получено $k = 15$ интервалов, для X2 — $k = 9$, для X3 — $k = 6$.




Рис. 1. Гистограммы и ЭФР для X1, X2, X3 с наложенными теоретическими кривыми

2.3. Ящики с усами и Q-Q графики




Рис. 2. Ящики с усами и Q-Q графики

2.4. Форма распределения

- X1: сильная правая асимметрия (коэф. асимметрии = 2.918), большой эксцесс (15.73). Значения сосредоточены вблизи нуля, есть редкие большие выбросы справа. Нижняя граница ≈ 10.73 (возможен сдвиг). Характерна экспоненциальная форма.
- X2: практически симметричное распределение (асимметрия = -0.17), эксцесс ≈ -0.29 (близко к нормальному). Гистограмма — колоколообразная форма, нет выраженных выбросов.
- X3: почти симметричное (асимметрия ≈ -0.11), эксцесс ≈ -1.16 (плоскостопое, что типично для равномерного). Значения ограничены [26.52, 68.35], гистограмма близка к прямоугольнику.

3. Предположение о виде закона распределения (задание 4.2)

1. **X1 ~ Exp(λ , c) — экспоненциальное распределение со сдвигом.** Сильная правая асимметрия (2.92), большой положительный эксцесс, форма гистограммы — монотонно убывающая с левым ограничением. Критерий KS не отвергает экспоненциальное распределение ($p = 0.453$), тогда как для нормального и равномерного $p < 0.001$.
2. **X2 ~ N(μ , σ) — нормальное распределение.** Практически симметричная форма (асимметрия -0.17), эксцесс близок к нулю, гистограмма колоколообразная. Q-Q график против нормального даёт почти прямую. KS-тест: $p = 0.822$.
3. **X3 ~ U(a , b) — равномерное распределение.** Отрицательный эксцесс (-1.16), гистограмма практически прямоугольная, данные ограничены с обеих сторон. Q-Q против равномерного — почти прямая. KS-тест: $p = 0.980$.

4. Оценивание параметров (задание 4.3)

4.1. X1 — экспоненциальное распределение Exp(λ , c)

Плотность: $f(x) = \lambda \cdot \exp(-\lambda(x-c))$, $x \geq c$. Теоретические моменты: $EX = c + 1/\lambda$, $DX = 1/\lambda^2$.

Метод моментов (МOM): $\hat{\lambda} = 1/S = 1/53.706 = 0.01862$; $\hat{c} = \bar{x} - 1/\hat{\lambda} = 64.046 - 53.706 = 10.340$

Метод максимального правдоподобия (ММП): $\hat{c} = \min\{x_i\} = 10.730$; $\hat{\lambda} = 1/(\bar{x} - \hat{c}) = 1/(64.046 - 10.730) = 0.01877$

Логарифм правдоподобия: $\ell(\lambda, c) = n \cdot \ln(\lambda) - \lambda \cdot \sum (x_i - c)$. Максимизация по $c \rightarrow \hat{c} = \min\{x_i\}$; максимизация по $\lambda \rightarrow \hat{\lambda} = 1/(\bar{x} - \hat{c})$.

Сравнение: оценки методов близки ($\hat{\lambda}_{\text{MOM}} = 0.01862$, $\hat{\lambda}_{\text{MLE}} = 0.01877$; $\hat{c}_{\text{MOM}} = 10.340$, $\hat{c}_{\text{MLE}} = 10.730$). Расхождение в $\hat{c} \approx 0.39$ — небольшое смещение MOM, так как MOM не учитывает жёсткое ограничение снизу.

4.2. X2 — нормальное распределение N(μ , σ)

Плотность: $f(x) = (1/\sqrt{2\pi\sigma^2}) \cdot \exp(-(x-\mu)^2/(2\sigma^2))$. Теоретические моменты: $EX = \mu$, $DX = \sigma^2$.

МOM: $\hat{\mu} = \bar{x} = 57.661$; $\hat{\sigma}^2 = S = 12.542$

ММП: $\hat{\mu} = \bar{x} = 57.661$; $\hat{\sigma}^2_{\text{MLE}} = S = 12.542$ (несмещённая: $\hat{\sigma}^2 = 12.574$)

Для нормального распределения оценки MOM и ММП совпадают. Разница между смещённой S и несмещённой $\hat{\sigma}^2$ минимальна при $n = 200$: $\sigma^2 = 158.099$ против $S^2 = 157.308$.

4.3. X3 — равномерное распределение U(a , b)

Плотность: $f(x) = 1/(b-a)$, $x \in [a, b]$. Теоретические моменты: $EX = (a+b)/2$, $DX = (b-a)^2/12$.

МOM: $\hat{a} = \bar{x} - \sqrt{(3S^2)} = 47.844 - \sqrt{(3 \cdot 142.73)} = 47.844 - 20.693 = 27.151$; $\hat{b} = \bar{x} + \sqrt{(3S^2)} = 68.537$

ММП: $\hat{a} = \min\{x_i\} = 26.520$; $\hat{b} = \max\{x_i\} = 68.350$

Логарифм правдоподобия: $\ell(a, b) = -n \cdot \ln(b-a)$ при $a \leq \min\{x_i\}$ и $b \geq \max\{x_i\}$. Максимизирован на $\hat{a} = \min\{x_i\}$, $\hat{b} = \max\{x_i\}$. Оценки MOM дают чуть более широкий интервал (27.15–68.54), ММП — более узкий (26.52–68.35), что точнее.

Таблица 2. Оценки параметров

Параметр	X1 (Exp)		X2 (Normal)		X3 (Uniform)	
	МОМ	ММП	МОМ	ММП	МОМ	ММП
a (или c)	10.34	10.73	57.66	57.66	—	—
b (или a_unif)	—	—	—	—	27.15	26.52
b_unif	—	—	—	—	68.54	68.35
λ (или σ)	0.0186	0.0188	12.54	12.54	—	—

5. Оценка вероятности $P(X > x_0)$ (задание 4.4)

Порог $x_0 = \bar{x} + \sigma$ (среднее плюс несмещённое ст. откл.).

Столбец	x_0	P_эмп	P_пар (выбр. модель)	P_норм	Расхождение
X1 (Exp)	117.887	0.1250	0.1340	0.1587	0.0090
X2 (Norm)	70.235	0.1800	0.1587	0.1587	0.0213
X3 (Unif)	59.821	0.2050	0.2039	0.1587	0.0011

Выводы: для X3 (равномерное) расхождение эмпирической и параметрической оценок минимально (0.0011) — модель хорошо описывает данные. Для X1 расхождение 0.009, для X2 — 0.021 (случайный разброс при $n = 200$). Нормальная формула для X1 даёт $P = 0.159$, что заметно выше эмпирического 0.125, так как нормальное распределение не подходит для этого столбца.

6. Моменты по сгруппированной выборке (задание 4.5)

Столбец	Бинов k	$\bar{x}_{\text{группы}}$	$\bar{x}_{\text{исходный}}$	$\sigma^2_{\text{группы}}$	$\sigma^2_{\text{исходный}}$
X1	15	64.558	64.046	2831.90	2898.79
X2	9	57.631	57.661	161.15	158.10
X3	6	47.923	47.844	138.49	143.45

Формулы для сгруппированной выборки: $\bar{x}_g = (1/n) \cdot \sum(n_k \cdot \hat{x}_k)$, $\sigma^2_g = (1/(n-1)) \cdot \sum(n_k \cdot (\hat{x}_k - \bar{x}_g)^2)$, где $\hat{x}_k$ — середина k-го интервала, n_k — частота.

Вывод: оценки по сгруппированной выборке хорошо совпадают с исходными. Небольшие расхождения (до 2.5%) обусловлены огрублением данных при группировке — каждое наблюдение заменяется серединой интервала. Чем больше интервалов, тем точнее оценки.

7. Доверительные интервалы (задание 4.6)

7.1. Асимптотические ДИ для EX (уровень доверия 0.95)

Формула: $[\bar{x} - z_{\{0.975\}} \cdot \sigma/\sqrt{n}, \bar{x} + z_{\{0.975\}} \cdot \sigma/\sqrt{n}]$, где $z_{\{0.975\}} = 1.96$.

Таблица 3. Доверительные интервалы

Столбец	Метод	Нижняя граница	Верхняя граница	Ширина
X1	Асимптотический (ЦПТ)	56.584	71.508	14.924
X2	Асимптотический (ЦПТ)	55.918	59.403	3.485
X2	Точный для μ (t-распр.)	55.918	59.403	3.485
X2	Точный для σ^2 (χ^2 -распр.)	130.96	192.89	—
X3	Асимптотический (ЦПТ)	46.184	49.504	3.320

7.2. Точные ДИ для параметров нормального распределения (X2)

Поскольку $X2 \sim N(a, \sigma^2)$, можно использовать точные интервалы, опирающиеся на t-распределение и χ^2 -распределение.

ДИ для μ (t-распределение, $df = 199$): $[\bar{x} - t_{\{0.975, 199\}} \cdot \sigma / \sqrt{n}, \bar{x} + t_{\{0.975, 199\}} \cdot \sigma / \sqrt{n}] = [55.918, 59.403]$, $t_{\{0.975, 199\}} = 1.972$.

ДИ для σ^2 (χ^2 -распределение): $[(n-1) \cdot \sigma^2 / \chi^2_{\{0.975, 199\}}, (n-1) \cdot \sigma^2 / \chi^2_{\{0.025, 199\}}] = [130.96, 192.89]$.

ДИ для σ : $[\sqrt{130.96}, \sqrt{192.89}] = [11.45, 13.89]$.

7.3. Интерпретация доверительных интервалов

Доверительный интервал уровня 0.95 означает следующее: если бы мы многократно брали выборки объёма $n = 200$ из одного и того же генерального распределения и каждый раз строили такой интервал по той же процедуре, то примерно в 95% случаев построенный интервал содержал бы истинное значение параметра. Это не означает, что «с вероятностью 0.95 параметр находится в этом интервале» — параметр является фиксированным числом, и конкретный построенный интервал либо содержит его, либо нет. Речь идёт о частотном свойстве самой процедуры построения.

Для X2 (нормальное) ширина ДИ для μ равна 3.485 — при стандартном отклонении ≈ 12.57 и $n = 200$ это достаточно узкий интервал, отражающий высокую точность оценки среднего при большой выборке. ДИ для $\sigma^2 = [130.96, 192.89]$ относительно шире, так как оценка дисперсии менее точна, чем оценка среднего.

8. анализ X4 (задание 6)



Рис. 3. Гистограмма, ЭФР и кластеры X4

Гистограмма X4 показывает ярко выраженную бимодальность: два чётко разделённых «горба» — около 25–30 и около 88–95. Эксцесс = -1.67 (плоскостопое). Среднее (57.65) находится в «долине» между модами и плохо описывает данные.

Кластеризация порогом $x_0 = 60$:

- Кластер 1 ($x \leq 60$): $n_1 = 106$, $\bar{x}_1 = 28.58$, $\sigma_1^2 = 9.31$, диапазон [4.58, 49.54]
- Кластер 2 ($x > 60$): $n_2 = 94$, $\bar{x}_2 = 90.42$, $\sigma_2^2 = 8.88$, диапазон [72.01, 114.08]

Два кластера имеют почти не перекрывающиеся диапазоны, близкие дисперсии, но средние, отличающиеся примерно на 62 единицы. Это типичная смесь двух нормальных (или равномерных) распределений. «Общее среднее» 57.65 не является характерным значением ни для одного из режимов — оно попадает в область с минимальной плотностью. Это демонстрирует опасность применения классических описательных статистик к неоднородным данным без предварительного анализа структуры.

9. Итоговый вывод (задание 4.7)

По результатам анализа выборки объёма $n = 200$ (вариант А-3) установлены следующие распределения:

4. **$X1 \sim \text{Exp}(\lambda, c)$** : $\lambda_{\text{MLE}} = 0.01877$, $\hat{c}_{\text{MLE}} = 10.730$. Правоскошенное распределение с нижним ограничением ≈ 10.73 . Асимптотический ДИ для $EX = [56.58, 71.51]$ (ширина 14.92) — относительно широкий из-за большого разброса данных.
5. **$X2 \sim N(57.66, 12.57^2)$** : Симметричное распределение. Оценки МОМ и ММП совпадают. ДИ для $\mu = [55.92, 59.40]$ (ширина 3.49) — узкий и точный. ДИ для $\sigma^2 = [130.96, 192.89]$.
6. **$X3 \sim U(26.52, 68.35)$** : Равномерное на [26.52, 68.35]. ДИ для $EX = [46.18, 49.50]$ (ширина 3.32). Наименьшее расхождение между эмпирической и параметрической оценками вероятности.
7. **$X4$** : Смесь двух компонент. Кластер 1: $N \approx N(28.6, 9.31^2)$, кластер 2: $N \approx N(90.4, 8.88^2)$. «Общее» среднее (57.65) не отражает ни один из режимов.

Точность оценок максимальна для $X2$ и $X3$ (узкие ДИ), что объясняется меньшими дисперсиями и хорошим соответствием параметрических моделей данным. Для $X1$ интервал шире из-за тяжёлого хвоста экспоненциального распределения. Во всех случаях оценки МОМ и ММП дали близкие результаты; наибольшее относительное расхождение — для параметра сдвига c у $X1$ (МОМ: 10.34, ММП: 10.73), что является теоретически ожидаемым эффектом.